



INSTITUTO POLITECNICO NACIONAL

Escuela Superior de Cómputo
(ESCOM)

Licenciatura en Ciencias de Datos.

Nombre de la unidad de aprendizaje:

Análisis de Series de Tiempo.

Grupo: 6AV1.

Nombre de la Actividad:

“Practica 7”.

Análisis de series de tiempo estacionaria”.

Integrantes:

Arteaga Gonzáles Edwin Yahir

Juárez Gaona Erick Rafael.

Rico Gaytán Diana Andrea.

Ruiz Merino Wendy Ivonne.

Fecha:

11/05/2025.

1. Introducción

El análisis de series de tiempo es fundamental para entender y predecir fenómenos que evolucionan con el tiempo. En este proyecto, se estudian los precios diarios promedio de hortalizas con el objetivo de modelarlos y pronosticarlos usando técnicas estadísticas. Se aplicó la metodología Box-Jenkins con un modelo ARIMA para generar estimaciones confiables y fundamentadas.

2. Problemática

En sectores como la agricultura, la planeación logística, el comercio y la seguridad alimentaria, es crucial anticipar los precios de productos perecederos como hortalizas. Estos precios tienden a fluctuar por razones climáticas, estacionales o de oferta/demanda. Un modelo predictivo puede ser útil para agricultores, comercializadores y autoridades para tomar mejores decisiones.

3. Modelo estadístico

Se utilizó el modelo ARIMA (Autoregressive Integrated Moving Average), útil para series temporales estacionarias o que pueden hacerse estacionarias mediante diferenciación.

- Estructura del modelo:
ARIMA(p, d, q)
 - p: número de rezagos autorregresivos (AR)
 - d: número de diferenciaciones para hacer la serie estacionaria
 - q: número de términos de media móvil (MA)

Para este análisis, se determinó que el mejor modelo fue:

ARIMA(3, 0, 1)

4. Modelo computacional

Herramientas utilizadas:

- Python 3.11
- Librerías: pandas, matplotlib, statsmodels

Pasos implementados:

1. Carga y limpieza del dataset: agriculture-vegetables-fruits-time-series-prices
2. Filtro por producto y ciudad: Precio promedio diario de hortalizas
3. Conversión de fechas y manejo de valores nulos
4. Prueba de estacionariedad (ADF)
5. Análisis ACF y PACF
6. Estimación manual de parámetros con comparación de AIC/BIC
7. Ajuste del modelo ARIMA y validación
8. Pronóstico a 30 días

5. Metodología (Box-Jenkins)

5.1 Identificación

- Se verificó que la serie fuera estacionaria con la prueba ADF ($p < 0.05$)
- Se analizaron las funciones ACF y PACF para proponer valores de p y q .

5.2 Estimación

- Se probaron combinaciones de (p, q) en $ARIMA(d=0)$, seleccionando la de menor AIC:

Mejor modelo: ARIMA(3, 0, 1)

5.3 Diagnóstico

- Se analizaron los residuos del modelo:
 - Ruido blanco (no autocorrelacionados)
 - Distribución simétrica alrededor de cero
 - Superaron visualmente las pruebas de independencia y normalidad

5.4 Pronóstico

- Se realizó un pronóstico a 30 días.
- Se encontró que, al no incorporar estacionalidad, el pronóstico tiende a una línea recta (valor medio esperado).

6. Propuesta de solución (con ARIMA)

El modelo ARIMA(3, 0, 1) genera un pronóstico que proyecta los valores futuros como una media suavizada, ideal para series que no muestran estacionalidad marcada. Es útil para análisis de corto plazo y series con poca variabilidad reciente.

Para mejorar la proyección a largo plazo o en presencia de ciclos, se recomienda usar SARIMA.

7. Conclusiones

Edwin Yahir Arteaga Gonzalez

Este proyecto me permitió aplicar de forma práctica la metodología Box-Jenkins para modelado de series temporales. Aprendí a estimar parámetros de ARIMA sin depender de funciones automáticas, interpretar ACF/PACF y evaluar residuos del modelo. El principal

reto fue distinguir cuándo usar ARIMA versus SARIMA. Considero que este tipo de modelos son aplicables para generar inteligencia predictiva en múltiples sectores.

Juárez Gaona Erick Rafael

A través de este análisis comprendí la importancia de verificar la estacionariedad en las series de tiempo antes de modelarlas. La prueba ADF y la visualización ACF/PACF fueron herramientas clave para ajustar un modelo confiable. Aunque ARIMA no captura estacionalidad, su uso es valioso para series con estructura más simple o sin patrones recurrentes marcados.

Rico Gaytán Diana Andrea

El ajuste manual de parámetros (p , d , q) me permitió entender cómo se comporta cada componente del modelo ARIMA. El hecho de probar múltiples combinaciones y analizar el AIC reforzó mi criterio para elegir el mejor modelo estadístico. Este proyecto refuerza la necesidad de validar los residuos para garantizar que el modelo no tenga errores estructurales.

Ruiz Merino Wendy Ivonne

Una de las lecciones clave fue identificar cuándo un modelo ARIMA es suficiente y cuándo no. El resultado del pronóstico como línea recta nos mostró que, aunque el modelo era válido, no era el mejor para capturar estacionalidad. Esto resalta la importancia de entender los límites del modelo que usamos, más allá de sus métricas estadísticas.

Conclusión General

El presente análisis permitió aplicar de forma integral la metodología Box-Jenkins para el modelado y pronóstico de una serie de tiempo real. A través del uso del modelo ARIMA, se logró capturar la dinámica estadística de los precios diarios promedio de hortalizas. Se realizaron pruebas rigurosas para asegurar la estacionariedad de la serie, se estimaron los parámetros óptimos mediante criterios de información como AIC y BIC, y se validó la

calidad del modelo mediante el análisis de residuos. Aunque el modelo ARIMA demostró ser adecuado en términos de ajuste, también se evidenció que su capacidad para capturar estacionalidad es limitada, lo que abre la puerta a explorar modelos más completos como SARIMA en futuras investigaciones. En conjunto, este trabajo demuestra cómo el enfoque estadístico combinado con herramientas computacionales puede contribuir a generar pronósticos confiables y útiles para la toma de decisiones en sectores estratégicos como la agricultura.