

Equipo1_Practica8Final

June 24, 2025

1 Práctica 8 Periodograma y Transformada discreta de fourier

Carrera: Licenciatura en Ciencia de Datos

Grupo: 6AV1

Materia: Análisis de Series de Tiempo

Docente: Daniel Jiménez Alcantar

Alumno:

- Aguilar Ramirez Carlos Francisco
- Arista Romero Juan Ismael
- Jiménez Flores Luis Arturo
- Vazquez Martin Marlene Gabriela

Fecha de última modificación: 13/06/2025

En esta práctica analizaremos el periodograma y la transformada discreta de fourier para analizar series de tiempo. Para esta práctica se hará uso de la metodología Box-Jenkins. La cual consta de 4 fases:

- Identificar el Modelo
- Estimación de Parámetros
- Validación
- Uso del Modelo

Comportamiento de los datos:

pib_mx, export, import: Son variables REALES, medidas en millones de pesos constantes de un año base.

pib_usa: Es una variable REAL, medida en miles de millones (billones) de dólares constantes de un año base.

deflactor: Es un índice de precios que, para este análisis, DEBE SER IGNORADO, ya que las variables principales ya son reales.

2 Análisis Univariado

Proceso para dicho análisis:

Metodología Box-Jenkins / ARIMA

¿Para qué sirve? Para entender la estructura de una sola serie temporal y pronosticar su futuro basándose únicamente en sus valores pasados.

Pregunta que responde: “Considerando solo el comportamiento histórico del crecimiento de México, ¿cuál es el pronóstico para el próximo trimestre?”

¿Se debe hacer dicho análisis para todas las variables? Sería útil si se quisiera tener un modelo de pronóstico individual para cada variable, pero no diría nada sobre cómo se afectan entre sí.

2.1 Importe de bibliotecas y del conjunto de datos

```
[ ]: # Instalar la librería openpyxl
!pip install openpyxl
```

```
Requirement already satisfied: openpyxl in
c:\users\arturojf\appdata\local\programs\python\python313\lib\site-packages
(3.1.5)
Requirement already satisfied: et-xmlfile in
c:\users\arturojf\appdata\local\programs\python\python313\lib\site-packages
(from openpyxl) (2.0.0)
```

```
[ ]: # Instalar la librería fsspec
!pip install fsspec
```

```
Requirement already satisfied: fsspec in
c:\users\arturojf\appdata\local\programs\python\python313\lib\site-packages
(2025.5.1)
```

```
[ ]: # Importar las librerías necesarias

# Para el análisis
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
# Importa la biblioteca warnings, utilizada para gestionar los mensajes de
    ↳ advertencia que aparecen durante la ejecución del código.
import warnings
# Configura las advertencias para que se ignoren, de manera que no se muestren
    ↳ en la salida.
warnings.filterwarnings('ignore')

# Para series de tiempo

# Identificación
from statsmodels.tsa.stattools import adfuller
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from scipy.signal import find_peaks
```

```
#Aplicación de periodogramas y transformada discreta de fourier
from scipy.signal import periodogram
from scipy.fft import fft, ifft, fftfreq

# Modelos
from statsmodels.tsa.arima.model import ARIMA
```

```
[ ]: # Cargar los datos desde un archivo Excel
# df_entrada = pd.read_excel('C://Users//ludwi//Desktop//Datos//
↳politica_comercial.xlsx')
df_entrada = pd.read_excel('C://Users//ARTUROJF//Desktop//Datos//
↳politica_comercial.xlsx')
```

```
[ ]: # Nombre que quieres para tu archivo CSV de salida
df_salida = 'ArchivoBase.csv'

# Conversión a csv
df_entrada.to_csv(df_salida, index=False, encoding='utf-8')
```

2.2 Análisis Exploratorio de los datos

```
[ ]: df_entrada.head(10)
```

```
[ ]:
      periodo      pib_mx      export      import  deflactor      tcn  \
0 1993-01-01  13800422.22  1782610.03  2073485.82  11.564787  3.105267
1 1993-04-01  13803814.43  1779169.28  2161980.95  11.844350  3.113633
2 1993-07-01  13964777.19  1826118.00  2208437.75  11.990366  3.116333
3 1993-10-01  14052691.98  1937013.00  2313888.41  12.137349  3.125600
4 1994-01-01  14191597.23  1925230.83  2463939.92  12.412881  3.171667
5 1994-04-01  14515785.03  1972085.50  2565911.07  12.721653  3.342600
6 1994-07-01  14596864.59  2044840.14  2621303.05  12.962410  3.394467
7 1994-10-01  14754320.27  2096742.42  2684584.55  13.399610  3.622067
8 1995-01-01  14075819.37  2526844.29  2044727.00  15.139769  5.994133
9 1995-04-01  13226005.31  2427914.88  2103634.57  17.734851  6.151233

      pib_usa
0  10576.275
1  10637.847
2  10688.606
3  10833.987
4  10939.116
5  11087.361
6  11152.176
7  11279.932
8  11319.951
9  11353.721
```

```
[ ]: df_politica = df_entrada

[ ]: df_politica.shape

[ ]: (128, 7)

[ ]: df_politica.columns.values

[ ]: array(['periodo', 'pib_mx', 'export', 'import', 'deflactor', 'tcn',
          'pib_usa'], dtype=object)

[ ]: df_politica.dtypes

[ ]: periodo      datetime64[ns]
     pib_mx        float64
     export        float64
     import        float64
     deflactor      float64
     tcn            float64
     pib_usa        float64
     dtype: object

[ ]: # Mover la columna 'periodo' para que sea el índice del DataFrame.
     # El argumento 'inplace=True' modifica el DataFrame directamente, por lo que no
     # necesitas reasignarlo.
     print("Estableciendo la columna 'periodo' como el índice del DataFrame...")
     df_politica.set_index('periodo', inplace=True)

     # Opcional: ¡Verifica el cambio! Corre .info() de nuevo.
     print("\nVerificando la nueva estructura del DataFrame:")
     df_politica.info()
```

Estableciendo la columna 'periodo' como el índice del DataFrame...

Verificando la nueva estructura del DataFrame:

```
<class 'pandas.core.frame.DataFrame'>
```

```
DatetimeIndex: 128 entries, 1993-01-01 to 2024-10-01
```

```
Data columns (total 6 columns):
```

#	Column	Non-Null Count	Dtype
0	pib_mx	128 non-null	float64
1	export	128 non-null	float64
2	import	128 non-null	float64
3	deflactor	128 non-null	float64
4	tcn	128 non-null	float64
5	pib_usa	128 non-null	float64

```
dtypes: float64(6)
```

```
memory usage: 7.0 KB
```

```
[ ]: df_politica.head(10)
```

```
[ ]:
      pib_mx      export      import  deflactor      tcn  \
periodo
1993-01-01  13800422.22  1782610.03  2073485.82  11.564787  3.105267
1993-04-01  13803814.43  1779169.28  2161980.95  11.844350  3.113633
1993-07-01  13964777.19  1826118.00  2208437.75  11.990366  3.116333
1993-10-01  14052691.98  1937013.00  2313888.41  12.137349  3.125600
1994-01-01  14191597.23  1925230.83  2463939.92  12.412881  3.171667
1994-04-01  14515785.03  1972085.50  2565911.07  12.721653  3.342600
1994-07-01  14596864.59  2044840.14  2621303.05  12.962410  3.394467
1994-10-01  14754320.27  2096742.42  2684584.55  13.399610  3.622067
1995-01-01  14075819.37  2526844.29  2044727.00  15.139769  5.994133
1995-04-01  13226005.31  2427914.88  2103634.57  17.734851  6.151233

      pib_usa
periodo
1993-01-01  10576.275
1993-04-01  10637.847
1993-07-01  10688.606
1993-10-01  10833.987
1994-01-01  10939.116
1994-04-01  11087.361
1994-07-01  11152.176
1994-10-01  11279.932
1995-01-01  11319.951
1995-04-01  11353.721
```

```
[ ]: ConteoNulos = df_politica.isnull().sum() # Esta línea cuenta cuántos valores
      ↪faltantes (nulos) hay en cada columna de tu DataFrame
ConteoNulos = ConteoNulos[ConteoNulos != 0] # Esta línea modifica la variable
      ↪"ConteoNulos" para que solo muestre las columnas que realmente tienen
      ↪valores faltantes.
porcentaje_nulos_calculado = df_politica.isnull().mean() * 100
porcentaje_nulos_calculado =
      ↪porcentaje_nulos_calculado[porcentaje_nulos_calculado != 0]

if ConteoNulos.empty:
    # Si ConteoNulos_filtrado está vacío, significa que ninguna columna tiene
    ↪nulos.
    print("No hay valores nulos en el DataFrame después del tratamiento.")
else:
    # Si hay nulos, procede a calcular porcentajes y crear el DataFrame para
    ↪mostrar.
    print("Las columnas que presentan datos nulos son las siguientes:\n",
          ↪sep='')
```

```
# Creas el DataFrame (que llamaste Diccionario_Nulos)
Diccionario_Nulos = pd.DataFrame({
    'Conteo': ConteoNulos,
    'Porcentaje (%)': porcentaje_nulos_calculado
})
print(Diccionario_Nulos)
```

No hay valores nulos en el DataFrame después del tratamiento.

```
[ ]: df_politica.info()
```

```
<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 128 entries, 1993-01-01 to 2024-10-01
Data columns (total 6 columns):
#   Column      Non-Null Count  Dtype
---  -
0   pib_mx      128 non-null    float64
1   export      128 non-null    float64
2   import      128 non-null    float64
3   deflator    128 non-null    float64
4   tcn         128 non-null    float64
5   pib_usa     128 non-null    float64
dtypes: float64(6)
memory usage: 7.0 KB
```

```
[ ]: df_politica.describe()
```

```
[ ]:
```

	pib_mx	export	import	deflator	tcn \
count	1.280000e+02	1.280000e+02	1.280000e+02	128.000000	128.000000
mean	1.995488e+07	6.113963e+06	6.668198e+06	66.723483	12.789908
std	3.434513e+06	2.584534e+06	2.767410e+06	34.084892	4.910913
min	1.322601e+07	1.779169e+06	2.044727e+06	11.564787	3.105267
25%	1.770210e+07	4.259244e+06	4.834021e+06	41.095961	9.474833
50%	2.014867e+07	5.464463e+06	6.641537e+06	64.883256	11.900833
75%	2.309912e+07	8.619922e+06	8.875224e+06	92.362208	17.593917
max	2.556910e+07	1.076406e+07	1.176880e+07	137.236371	23.337233

	pib_usa
count	128.000000
mean	16716.567758
std	3466.559261
min	10576.275000
25%	14206.667000
50%	16728.238000
75%	19224.541500
max	23542.349000

2.3 Econometría

```
[ ]: # Asignamos las columnas originales, asumiendo que ya son reales.
# Esto aplica probablemente también a exportaciones e importaciones.
print("Asignando variables reales (SIN deflactar)...")
df_politica['pib_mx_real'] = df_politica['pib_mx']
df_politica['export_real'] = df_politica['export']
df_politica['import_real'] = df_politica['import']
# El PIB de USA ya era real.
df_politica['pib_usa_real'] = df_politica['pib_usa']
```

Asignando variables reales (SIN deflactar)...

PIB de México (pib_mx): Está en Millones de Pesos Mexicanos (MXN) a precios corrientes (nominales).

PIB de USA (pib_usa): Está en Miles de Millones de Dólares Estadounidenses (USD), muy probablemente a precios constantes (reales) de un año base (ej. “Billions of Chained 2017 Dollars”).

Debido a esto, se va a seleccionar un tipo de cambio base para manejar los datos de homogénea para evitar sesgos. Esta base será millones de dólares.

Variables a Convertir de Pesos a Dólares:

- pib_mx (o mejor, su versión real, pib_mx_real)
- export (su versión real, export_real)
- import (su versión real, import_real)

Variable a Ajustar Unidades (de Billones a Millones de USD):

- pib_usa (su versión real, pib_usa_real)

Variables que NO se Convierten:

- tcn (Tipo de Cambio Nominal): Esta es tu herramienta de conversión. No debes convertirla; debes usarla para convertir las otras.

La Lógica de la Conversión

De Pesos a Dólares: Para convertir una cantidad de pesos a dólares, tienes que dividirla por el número de pesos que cuesta un dólar. La fórmula es:

$$\text{Valor en Dólares} = \frac{\text{Valor en Pesos}}{\text{Tipo de Cambio (tcn)}}$$

Usaremos las variables reales que ya calculamos para obtener una comparación más significativa.

```
[ ]: # --- Convertir las variables de México de Pesos Reales a Dólares ---
# La unidad resultante será "Millones de Dólares" porque (Millones de MXN) /
# ↪ (MXN por USD) = Millones de USD.
df_politica['pib_mx_usd'] = df_politica['pib_mx_real'] / df_politica['tcn']
df_politica['export_usd'] = df_politica['export_real'] / df_politica['tcn']
```

```
df_politica['import_usd'] = df_politica['import_real'] / df_politica['tcn']
```

De Billones a Millones de Dólares: Para esto se debe saber que 1 billón = 1,000 millones. Por lo tanto, para convertir el PIB de USA de miles de millones (billones) a millones, simplemente lo multiplicamos por 1,000.

Valor en Millones = Valor en Billones \times 1000

```
[ ]: # --- Ajustar las unidades del PIB de USA ---
# La unidad original es "Billones de USD", la convertimos a "Millones de USD".
df_politica['pib_usa_usd'] = df_politica['pib_usa_real'] * 1000

# --- 5c. Inspeccionar los resultados ---
# Seleccionamos las nuevas columnas en USD para ver el resultado.
columnas_usd = ['pib_mx_usd', 'export_usd', 'import_usd', 'pib_usa_usd']
print("\nDataFrame con las nuevas columnas en Millones de Dólares (USD):")
print(df_politica[columnas_usd].head())
```

DataFrame con las nuevas columnas en Millones de Dólares (USD):

	pib_mx_usd	export_usd	import_usd	pib_usa_usd
periodo				
1993-01-01	4.444199e+06	574060.208463	667731.967196	10576275.0
1993-04-01	4.433346e+06	571412.587652	694359.521031	10637847.0
1993-07-01	4.481156e+06	585982.885870	708665.445502	10688606.0
1993-10-01	4.495998e+06	619725.172767	740302.153187	10833987.0
1994-01-01	4.474492e+06	607009.194955	776859.669995	10939116.0

Se aplica el logaritmo debido a que al hacer esto. Convierte los datos a tasas de crecimiento porcentual, estabiliza la varianza y lineariza las relaciones, preparando los datos para un modelado estadístico válido. A este proceso se le conoce como elasticidad.

```
[ ]: # --- APLICAR LA TRANSFORMACIÓN LOGARÍTMICA A LAS VARIABLES EN USD ---
print("Aplicando transformación logarítmica a las variables en USD...")

df_politica['log_pib_mx_usd'] = np.log(df_politica['pib_mx_usd'])
df_politica['log_pib_usa_usd'] = np.log(df_politica['pib_usa_usd'])
df_politica['log_export_usd'] = np.log(df_politica['export_usd'])
df_politica['log_import_usd'] = np.log(df_politica['import_usd'])

# El tipo de cambio (tcn) no se convierte, pero sí se suele usar su logaritmo
# en los modelos.
df_politica['log_tcn'] = np.log(df_politica['tcn'])
```

Aplicando transformación logarítmica a las variables en USD...

```
[ ]: # CÁLCULO DE TASAS DE CRECIMIENTO (PARA ESTACIONARIEDAD)
# -----
print("Calculando tasas de crecimiento...")
```



```
df_politica['crecimiento_pib_mx_usd'] = df_politica['log_pib_mx_usd'].diff()
df_politica['crecimiento_pib_usa_usd'] = df_politica['log_pib_usa_usd'].diff()
df_politica['crecimiento_export_usd'] = df_politica['log_export_usd'].diff()
df_politica['crecimiento_import_usd'] = df_politica['log_import_usd'].diff()
df_politica['variacion_tcn'] = df_politica['log_tcn'].diff()
```

Calculando tasas de crecimiento...

```
[ ]: # --- Verificación Final ---
print("\n¡Proceso completado! DataFrame listo para el análisis.")
print("Últimas filas del DataFrame final:")
print(df_politica.tail())
```

¡Proceso completado! DataFrame listo para el análisis.

Últimas filas del DataFrame final:

	pib_mx	export	import	deflactor	tcn \
periodo					
2023-10-01	25272662.02	9372085.24	11180145.37	130.050781	17.557933
2024-01-01	25264616.11	9462510.70	11400486.44	130.139883	16.997433
2024-04-01	25337212.62	9604575.26	11459276.52	132.104993	17.245933
2024-07-01	25569100.57	10180806.19	11628061.21	134.561019	18.944033
2024-10-01	25407548.99	10550708.06	11768804.48	137.236371	20.087467

	pib_usa	pib_mx_real	export_real	import_real	pib_usa_real \
periodo					
2023-10-01	22960.600	25272662.02	9372085.24	11180145.37	22960.600
2024-01-01	23053.545	25264616.11	9462510.70	11400486.44	23053.545
2024-04-01	23223.906	25337212.62	9604575.26	11459276.52	23223.906
2024-07-01	23400.294	25569100.57	10180806.19	11628061.21	23400.294
2024-10-01	23542.349	25407548.99	10550708.06	11768804.48	23542.349

	...	log_pib_mx_usd	log_pib_usa_usd	log_export_usd \
periodo	...			
2023-10-01	...	14.179728		13.187740
2024-01-01	...	14.211853		13.229786
2024-04-01	...	14.200208		13.230174
2024-07-01	...	14.115406		13.194526
2024-10-01	...	14.050461		13.171607

	log_import_usd	log_tcn	crecimiento_pib_mx_usd \
periodo			
2023-10-01	13.364144	2.865506	-0.025182
2024-01-01	13.416104	2.833062	0.032125
2024-04-01	13.406734	2.847576	-0.011645
2024-07-01	13.327443	2.941489	-0.084802
2024-10-01	13.280867	3.000096	-0.064945

	crecimiento_pib_usa_usd	crecimiento_export_usd \
periodo		
2023-10-01	0.007856	-0.027019
2024-01-01	0.004040	0.042046
2024-04-01	0.007363	0.000388
2024-07-01	0.007566	-0.035648
2024-10-01	0.006052	-0.022918

	crecimiento_import_usd	variacion_tcn
periodo		
2023-10-01	-0.028299	0.028832
2024-01-01	0.051960	-0.032444
2024-04-01	-0.009370	0.014514
2024-07-01	-0.079291	0.093913
2024-10-01	-0.046576	0.058607

[5 rows x 24 columns]

```
[ ]: # --- Graficar la Evolución del PIB de México en Dólares (Escala Lineal) ---


# Crear la figura y los ejes para el gráfico
plt.figure(figsize=(14, 7))

# Graficar únicamente la serie de México en Millones de USD
plt.plot(df_politica.index, df_politica['pib_mx_usd'], label='PIB Real México_
↳(Millones USD)')

# Añadir títulos y etiquetas
plt.title('Evolución del PIB Real de México en Dólares (Escala Lineal)')
plt.xlabel('Periodo')
plt.ylabel('Millones de USD')
plt.legend()
plt.grid(True)

# Formatear el eje Y para que los números grandes sean más legibles
from matplotlib.ticker import FuncFormatter
def millions_formatter(x, pos):
    return f'{int(x):,}'
plt.gca().yaxis.set_major_formatter(FuncFormatter(millions_formatter))

# Mostrar el gráfico
plt.show()
```



```
[ ]: # --- Graficar la Evolución del PIB de Estados Unidos en Dólares (Escala
↳Lineal) ---


# Crear la figura y los ejes para el gráfico
plt.figure(figsize=(14, 7))

# Graficar únicamente la serie de EE.UU. en Millones de USD
plt.plot(df_politica.index, df_politica['pib_usa_usd'], label='PIB Real USA_
↳(Millones USD)', color='darkorange', linestyle='--')

# Añadir títulos y etiquetas
plt.title('Evolución del PIB Real de Estados Unidos (Escala Lineal)')
plt.xlabel('Periodo')
plt.ylabel('Millones de USD')
plt.legend()
plt.grid(True)

# Formatear el eje Y para que los números grandes sean más legibles
from matplotlib.ticker import FuncFormatter
def millions_formatter(x, pos):
    return f'{int(x):,}'
plt.gca().yaxis.set_major_formatter(FuncFormatter(millions_formatter))

# Mostrar el gráfico
plt.show()
```



```
[ ]: # Estas son las series estacionarias que se usarán en el modelo.
# También se puede calcular como (Valor_Nuevo - Valor_Viejo) / Valor_Viejo
print("Calculando las tasas de crecimiento desde las variables en logaritmos y_
↳USD...")


df_politica['crecimiento_pib_mx_usd'] = df_politica['log_pib_mx_usd'].diff()
df_politica['crecimiento_pib_usa_usd'] = df_politica['log_pib_usa_usd'].diff()
df_politica['crecimiento_export_usd'] = df_politica['log_export_usd'].diff()
df_politica['crecimiento_import_usd'] = df_politica['log_import_usd'].diff()

# La variación del tipo de cambio no se convierte, por lo que su cálculo no_
↳cambia.
df_politica['variacion_tcn'] = df_politica['log_tcn'].diff()
```

Calculando las tasas de crecimiento desde las variables en logaritmos y USD...

```
[ ]: # --- Visualizar las series transformadas para entender su comportamiento ---
print("Visualizando la evolución del PIB Real (en escala logarítmica)...")
plt.figure(figsize=(14, 7))
df_politica['log_pib_mx_usd'].plot(label='Log(PIB Real México)', legend=True)
df_politica['log_pib_usa_usd'].plot(label='Log(PIB Real USA)', legend=True,
↳linestyle='--')
plt.title('Evolución del PIB Real (México vs. USA)')
plt.ylabel('Escala Logarítmica')
plt.grid(True)
plt.show()
```

Visualizando la evolución del PIB Real (en escala logarítmica)...



2.4 Análisis Exploratorio de Series de Tiempo

En este proyctecto analizaremos dos series.

- La serie `log_pib_mx_usd` representa el NIVEL de la economía. Es la foto de qué tan grande es la economía en un momento dado. Esta serie tiene tendencia y ciclos.
- La serie `crecimiento_pib_mx_usd` representa el CAMBIO de la economía. Es la “velocidad” a la que la economía crece o se contrae de un trimestre a otro. Esta serie ya no tiene tendencia (es estacionaria).

Esto debido a que son dos herramientas que se derivan la una de la otra y que se usan en diferentes momentos para responder distintas preguntas y para cumplir con los requisitos de los modelos econométricos.

2.4.1 Serie de crecimiento

```
[ ]: # --- Graficar la Tasa de Crecimiento Trimestral ---

# Asegurarnos que la serie no tenga valores nulos para graficar
serie_a_graficar = df_politica['crecimiento_pib_mx_usd'].dropna()

# Crear la figura y los ejes para el gráfico
plt.figure(figsize=(14, 7))

# Graficar la serie de crecimiento a lo largo del tiempo
plt.plot(serie_a_graficar.index, serie_a_graficar, label='Tasa de Crecimiento_
↪Trimestral')
```


```

# Añadir una línea horizontal en cero para distinguir crecimiento de contracción
plt.axhline(y=0, color='r', linestyle='--', linewidth=1.5, label='Crecimiento ↵
↵Cero')

# Añadir títulos y etiquetas para mayor claridad
plt.title('Crecimiento Trimestral del PIB Real de México (en Dólares)')
plt.xlabel('Periodo')
plt.ylabel('Tasa de Crecimiento (aprox. % trimestral)')
plt.legend()
plt.grid(True)

# Mostrar el gráfico
plt.show()

```



Estadística Descriptiva Crecimiento

```

[ ]: # --- ANÁLISIS DE ESTADÍSTICA DESCRIPTIVA ---

# Seleccionar la serie y eliminar el valor NaN inicial
# Es crucial usar .dropna() para que los cálculos no se vean afectados.
serie_crecimiento = df_politica['crecimiento_pib_mx_usd'].dropna()

# Calcular las estadísticas descriptivas
print("--- Estadísticas Descriptivas del Crecimiento del PIB de México (en USD) ↵
↵---")

mean_value = serie_crecimiento.mean()
median_value = serie_crecimiento.median()

```

```

# La moda es menos informativa para datos continuos, pero la calculamos por
↳completitud.
mode_value = serie_crecimiento.mode().iloc[0] if not serie_crecimiento.mode().
↳empty else 'N/A'
std_dev = serie_crecimiento.std()
variance = serie_crecimiento.var()
# Calculamos los percentiles para entender los extremos
percentiles = serie_crecimiento.quantile([0.01, 0.05, 0.95, 0.99])

# Presentar los resultados de forma ordenada
stats_results = {
    "Promedio (Media)": mean_value,
    "Mediana": median_value,
    "Moda": mode_value,
    "Desviación Estándar": std_dev,
    "Varianza": variance
}

print("\nEstadísticas básicas:")
# Usamos un bucle para imprimir los resultados formateados
for key, value in stats_results.items():
    # El :.4f formatea el número para que tenga 4 decimales
    print(f" {key}: {value:.4f}")

print("\nPercentiles extremos:")
print(percentiles)

```

--- Estadísticas Descriptivas del Crecimiento del PIB de México (en USD) ---

Estadísticas básicas:

```

Promedio (Media): -0.0099
Mediana: 0.0002
Moda: -0.5508
Desviación Estándar: 0.0767
Varianza: 0.0059

```

Percentiles extremos:

```

0.01    -0.336669
0.05    -0.087285
0.95     0.058666
0.99     0.109173

```

Name: crecimiento_pib_mx_usd, dtype: float64

Granularidad, Máximos y Mínimos

[]: # --- ANÁLISIS DE GRANULARIDAD, MÁXIMOS Y MÍNIMOS ---

```

print("--- Análisis de Granularidad, Máximos y Mínimos ---")

```

```

# Análisis de Granularidad
# Verifica la diferencia de días entre cada punto de datos.
# Como tus datos son trimestrales, esperamos ver números alrededor de 90-92
↪ días.
print("\nAnálisis de Granularidad:")
if isinstance(serie_crecimiento.index, pd.DatetimeIndex):
    # Calcula la diferencia en días entre cada fecha del índice
    dias_diferencia = serie_crecimiento.index.to_series().diff().dt.days
    # Cuenta las diferencias más comunes para ver la frecuencia
    conteo_diferencias = dias_diferencia.value_counts().head()

    print("Diferencias más frecuentes en días entre registros:")
    print(conteo_diferencias)
else:
    print("El índice no es de tipo DatetimeIndex, no se puede calcular la
↪ granularidad.")

# Máximos y Mínimos globales
print("\nAnálisis de Extremos Globales:")
max_growth_val = serie_crecimiento.max()
max_growth_date = serie_crecimiento.idxmax()
min_growth_val = serie_crecimiento.min()
min_growth_date = serie_crecimiento.idxmin()

# Imprimimos los resultados formateados
print(f"Máximo crecimiento trimestral: {max_growth_val:.4f} (aprox.
↪ {max_growth_val:.2%}) el {max_growth_date.strftime('%Y-%m-%d')}")
print(f"Mínimo crecimiento (peor contracción): {min_growth_val:.4f} (aprox.
↪ {min_growth_val:.2%}) el {min_growth_date.strftime('%Y-%m-%d')}")

```

--- Análisis de Granularidad, Máximos y Mínimos ---

Análisis de Granularidad:

Diferencias más frecuentes en días entre registros:

periodo

92.0 63

91.0 40

90.0 23

Name: count, dtype: int64

Análisis de Extremos Globales:

Máximo crecimiento trimestral: 0.1977 (aprox. 19.77%) el 2020-07-01

Mínimo crecimiento (peor contracción): -0.5508 (aprox. -55.08%) el 1995-01-01

Granularidad: Las diferencias más frecuentes son 90, 91 y 92 días.

Confirma que los datos son consistentemente trimestrales.

La Duración de un Trimestre en Días: Como los meses tienen diferente número de días (30, 31, o 28/29), la duración de un trimestre no es constante.

Calculemos:

- Trimestre 1 (Enero, Febrero, Marzo): $31 + 28/29 + 31 = 90$ días (o 91 en año bisiesto).
- Trimestre 2 (Abril, Mayo, Junio): $30 + 31 + 30 = 91$ días.
- Trimestre 3 (Julio, Agosto, Septiembre): $31 + 31 + 30 = 92$ días.
- Trimestre 4 (Octubre, Noviembre, Diciembre): $31 + 30 + 31 = 92$ días.

Dando así resultados tales como: * 92.0 días (63 veces) * 91.0 días (40 veces) * 90.0 días (23 veces)

Extremos Globales: Los resultados son históricamente coherentes:

Mínimo (Peor Contracción) en 1995-01-01: Corresponde exactamente al “Efecto Tequila”, la crisis más severa de ese periodo.

Máximo Crecimiento en 2020-07-01: Corresponde al masivo rebote económico del tercer trimestre de 2020, justo después del parón inicial por la pandemia.

Análisis de Tendencia (Media Móvil) Como nuestros datos son trimestrales, una ventana de 4 periodos equivaldrá a una media móvil anual (4 trimestres = 1 año).

```
[ ]: # --- ANÁLISIS DE TENDENCIA CON MEDIA MÓVIL ANUAL ---

# Definir la ventana móvil
# Usamos 4 porque nuestros datos son trimestrales (4 trimestres = 1 año)
ventana_movil = 4

# Calcular la media móvil
serie_media_movil = serie_crecimiento.rolling(window=ventana_movil).mean()

# Graficar ambas series
print("Generando gráfico de tendencia con media móvil...")
plt.figure(figsize=(14, 7))


# Graficar la serie original con un poco de transparencia
plt.plot(serie_crecimiento.index, serie_crecimiento, alpha=0.6, label='Log(PIB_
↳Real México en USD)')

# Graficar la media móvil con una línea más gruesa y de otro color
plt.plot(serie_media_movil.index, serie_media_movil, color='red', linewidth=2,
↳label=f'Media Móvil {ventana_movil} trimestres (Anual)')

# Añadir títulos y etiquetas adecuados
plt.title('Análisis de Tendencia del PIB de México con Media Móvil')
plt.xlabel('Año')
plt.ylabel('Escala Logarítmica')
plt.legend()
```

```
plt.grid(True)
plt.tight_layout()
plt.show()
```

Generando gráfico de tendencia con media móvil...



Línea Azul (semitransparente): Es tu serie original `log_pib_mx_usd`, con toda su volatilidad y ruido trimestre a trimestre.

Línea Roja (gruesa): Es la versión “suavizada” de la serie. Esta línea es mucho más útil para ver la tendencia fundamental de la economía a lo largo del tiempo, ya que promedia las fluctuaciones de corto plazo.

Con la línea roja se puede identificar mucho más fácilmente los grandes ciclos económicos tales como: la caída post-1995, su la recuperación y caída hasta 2008, el estancamiento posterior y los efectos de la pandemia, sin la distracción del “ruido” trimestral.

Picos y Valles Locales (Exploratorio)

```
[ ]: # --- IDENTIFICACIÓN DE PICOS Y VALLES DEL CICLO ECONÓMICO ---

# Definir la distancia mínima entre picos/valles (en trimestres)
distancia_entre_picos = 12 # Equivalente a 3 años

# Encontrar los picos (máximos locales)
indices_picos, _ = find_peaks(serie_crecimiento, distance=distancia_entre_picos)
picos = serie_crecimiento.iloc[indices_picos]

# Encontrar los valles (mínimos locales), invirtiendo la serie
indices_valles, _ = find_peaks(-serie_crecimiento,
    ↪distance=distancia_entre_picos)
```

```

valles = serie_crecimiento.iloc[indices_valles]

# Graficar los resultados
print("Generando gráfico de picos y valles del ciclo económico...")
plt.figure(figsize=(14, 7))

# Graficar la serie original
plt.plot(serie_crecimiento.index, serie_crecimiento, label='Log(PIB Real México_
↳ en USD)')

# Marcar los picos en el gráfico
plt.scatter(picos.index, picos.values, color='red', marker='^', s=100,
↳ label='Picos del Ciclo Económico')


# Marcar los valles en el gráfico
plt.scatter(valles.index, valles.values, color='green', marker='v', s=100,
↳ label='Valles del Ciclo Económico')

# Añadir títulos y etiquetas
plt.title(f'Picos y Valles del Ciclo Económico de México (distancia =
↳ {distancia_entre_picos} trimestres)')
plt.xlabel('Año')
plt.ylabel('Escala Logarítmica')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# Imprimir un resumen
print(f"Número de picos locales detectados: {len(picos)}")
print(f"Número de valles locales detectados: {len(valles)}")

```

Generando gráfico de picos y valles del ciclo económico...



Número de picos locales detectados: 8

Número de valles locales detectados: 8

Razones de Crecimiento Anual (Exploratorio)

```
[ ]: # --- CÁLCULO Y VISUALIZACIÓN DEL CRECIMIENTO ANUAL ---

# 1. Seleccionar la serie de interés (valor del PIB en USD, no la tasa de
    ↪ crecimiento)
serie_anual = df_politica['pib_mx_usd']

print("Calculando el crecimiento/reducción anual...")

# 2. Agrupar por año y tomar el último valor de cada año
# Usamos el último dato trimestral como representativo del cierre del año.
valores_anuales = serie_anual.resample('A').last() # .resample('A') es más
    ↪ robusto que groupby(year)

# 3. Calcular el cambio porcentual año con año
crecimiento_anual = valores_anuales.pct_change() * 100

# 4. Preparar los datos para la visualización
crecimiento_anual_df = crecimiento_anual.dropna().reset_index()
crecimiento_anual_df.columns = ['Año', 'Crecimiento (%)']
# Extraemos solo el año para que el eje X sea más limpio
crecimiento_anual_df['Año'] = crecimiento_anual_df['Año'].dt.year

print("Primeras filas del crecimiento anual:")
print(crecimiento_anual_df.head())
```

```

# 5. Graficar los resultados como un diagrama de barras
plt.figure(figsize=(14, 7))
sns.barplot(data=crecimiento_anual_df, x='Año', y='Crecimiento (%)',
            palette='coolwarm')

# Ajustar las etiquetas del eje X para que no se solapen
plt.xticks(rotation=45, ha='right', fontsize=9)

# Añadir títulos y etiquetas
plt.title('Crecimiento/Reducción Anual del PIB Real de México (en USD)')
plt.xlabel('Año')
plt.ylabel('Crecimiento Anual (%)')
plt.grid(axis='y', linestyle='--', alpha=0.7)

# Ajustar la frecuencia de los 'ticks' en el eje x para mayor claridad
ax = plt.gca()
n_years = len(crecimiento_anual_df['Año'])
# Muestra una etiqueta cada 'tick_spacing' años. Ajusta el divisor si es
# necesario.
tick_spacing = max(1, n_years // 25)
ax.set_xticks(ax.get_xticks()[::tick_spacing])


plt.tight_layout()
plt.show()

```

Calculando el crecimiento/reducción anual...

Primeras filas del crecimiento anual:

	Año	Crecimiento (%)
0	1994	-9.398239
1	1995	-53.891252
2	1996	1.720597
3	1997	4.500732
4	1998	-16.924553



Barras Azules (Positivas): Representan los años en que el valor en dólares del PIB de México creció en comparación con el cierre del año anterior.

Barras Rojas (Negativas): Son los años de recesión o contracción. Indican que el valor en dólares del PIB fue menor que el del año anterior. Verás barras rojas muy grandes en años de crisis como 1995, 2009 y 2020.

La Altura de las Barras: La altura (o profundidad) de cada barra te muestra la magnitud del cambio. Una barra roja muy alta en 1995 te mostrará visualmente el devastador impacto de la crisis del Tequila en el valor de la economía medido en dólares.

2.4.2 Serie elástica

Análisis de Tendencia (Media Móvil)

```
[ ]: # --- ANÁLISIS DE TENDENCIA CON MEDIA MÓVIL ANUAL ---

# 1. Seleccionar la serie de interés (la de niveles en logaritmos, no la de crecimiento)
serie_a_analizar = df_politica['log_pib_mx_usd'].dropna()

# 2. Definir la ventana móvil
# Usamos 4 porque nuestros datos son trimestrales (4 trimestres = 1 año)
ventana_movil = 4

# 3. Calcular la media móvil
serie_media_movil = serie_a_analizar.rolling(window=ventana_movil).mean()

# 4. Graficar ambas series
print("Generando gráfico de tendencia con media móvil...")
plt.figure(figsize=(14, 7))
```

```


# Graficar la serie original con un poco de transparencia
plt.plot(serie_a_analizar.index, serie_a_analizar, alpha=0.6, label='Log(PIB_
↳Real México en USD)')

# Graficar la media móvil con una línea más gruesa y de otro color
plt.plot(serie_media_movil.index, serie_media_movil, color='red', linewidth=2,
↳label=f'Media Móvil {ventana_movil} trimestres (Anual)')

# Añadir títulos y etiquetas adecuados
plt.title('Análisis de Tendencia del PIB de México con Media Móvil')
plt.xlabel('Año')
plt.ylabel('Escala Logarítmica')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

```

Generando gráfico de tendencia con media móvil...



Picos y Valles Locales (Exploratorio)

```

[ ]: # --- IDENTIFICACIÓN DE PICOS Y VALLES DEL CICLO ECONÓMICO ---

# 1. Seleccionar la serie de interés
serie_ciclos = df_politica['log_pib_mx_usd'].dropna()

# 2. Definir la distancia mínima entre picos/valles (en trimestres)
distancia_entre_picos = 12 # Equivalente a 3 años

```

```

# 3. Encontrar los picos (máximos locales)
indices_picos, _ = find_peaks(serie_ciclos, distance=distancia_entre_picos)
picos = serie_ciclos.iloc[indices_picos]

# 4. Encontrar los valles (mínimos locales), invirtiendo la serie
indices_valles, _ = find_peaks(-serie_ciclos, distance=distancia_entre_picos)
valles = serie_ciclos.iloc[indices_valles]

# 5. Graficar los resultados
print("Generando gráfico de picos y valles del ciclo económico...")
plt.figure(figsize=(14, 7))

# Graficar la serie original
plt.plot(serie_ciclos.index, serie_ciclos, label='Log(PIB Real México en USD)')

# Marcar los picos en el gráfico
plt.scatter(picos.index, picos.values, color='red', marker='^', s=100,
            label='Picos del Ciclo Económico')


# Marcar los valles en el gráfico
plt.scatter(valles.index, valles.values, color='green', marker='v', s=100,
            label='Valles del Ciclo Económico')

# Añadir títulos y etiquetas
plt.title(f'Picos y Valles del Ciclo Económico de México (distancia = {distancia_entre_picos} trimestres)')
plt.xlabel('Año')
plt.ylabel('Escala Logarítmica')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# Imprimir un resumen
print(f"Número de picos locales detectados: {len(picos)}")
print(f"Número de valles locales detectados: {len(valles)}")

```

Generando gráfico de picos y valles del ciclo económico...



Número de picos locales detectados: 7
 Número de valles locales detectados: 8

2.5 Metodología Box-Jenkins

2.5.1 Identificación del Modelo

El objetivo aquí es encontrar el modelo ARIMA(p, d, q) más apropiado. Como ya hemos diferenciado los logaritmos para obtener las tasas de crecimiento, estamos trabajando con una serie que probablemente ya es estacionaria. Por lo tanto, el orden de diferenciación d que necesitaremos aplicar a esta serie de crecimiento será 0.

Nuestro objetivo es encontrar los órdenes p (autorregresivo) y q (media móvil).

Preparar la Serie y Verificar Estacionariedad Usamos una prueba estadística formal como la Prueba Aumentada de Dickey-Fuller (ADF) para confirmar que es estacionaria.

Hipótesis Nula (H0): La serie tiene una raíz unitaria (no es estacionaria).

Hipótesis Alternativa (Ha): La serie no tiene una raíz unitaria (es estacionaria).

Si el p-valor es menor a 0.05, rechazamos la hipótesis nula.

```
[ ]: # Seleccionar la serie de crecimiento del PIB de México y eliminar el primer
      ↪ valor NaN
serie_crecimiento_mx = df_politica['crecimiento_pib_mx_usd'].dropna()

# Realizar la prueba ADF
resultado_adf = adfuller(serie_crecimiento_mx)
print('--- Prueba Aumentada de Dickey-Fuller (ADF) ---')
print(f'Estadístico ADF: {resultado_adf[0]}')
```

```

print(f'p-valor: {resultado_adf[1]}')

if resultado_adf[1] <= 0.05:
    print("Conclusión: El p-valor es menor o igual a 0.05. Se rechaza la hipótesis nula. La serie es estacionaria.")
    print("El orden de diferenciación (d) para el modelo ARIMA será 0.")
else:
    print("Conclusión: El p-valor es mayor a 0.05. No se rechaza la hipótesis nula. La serie no es estacionaria.")

```

--- Prueba Aumentada de Dickey-Fuller (ADF) ---

Estadístico ADF: -8.002700781844236

p-valor: 2.3110629485815235e-12

Conclusión: El p-valor es menor o igual a 0.05. Se rechaza la hipótesis nula. La serie es estacionaria.

El orden de diferenciación (d) para el modelo ARIMA será 0.

Analizar Gráficos ACF y PACF Estos gráficos son nuestra herramienta principal para elegir los órdenes p y q.

ACF (Función de Autocorrelación): Nos ayuda a identificar el orden q (MA). PACF (Función de Autocorrelación Parcial): Nos ayuda a identificar el orden p (AR).

Para el crecimiento

```

[ ]: # --- Gráfico de Autocorrelación (ACF) ---
print("Función de Autocorrelación (ACF):")
fig_acf = plt.figure(figsize=(12, 4))
ax_acf = fig_acf.add_subplot(111)
plot_acf(serie_crecimiento_mx, ax=ax_acf, lags=20)
plt.title('Función de Autocorrelación (ACF)')
plt.show()

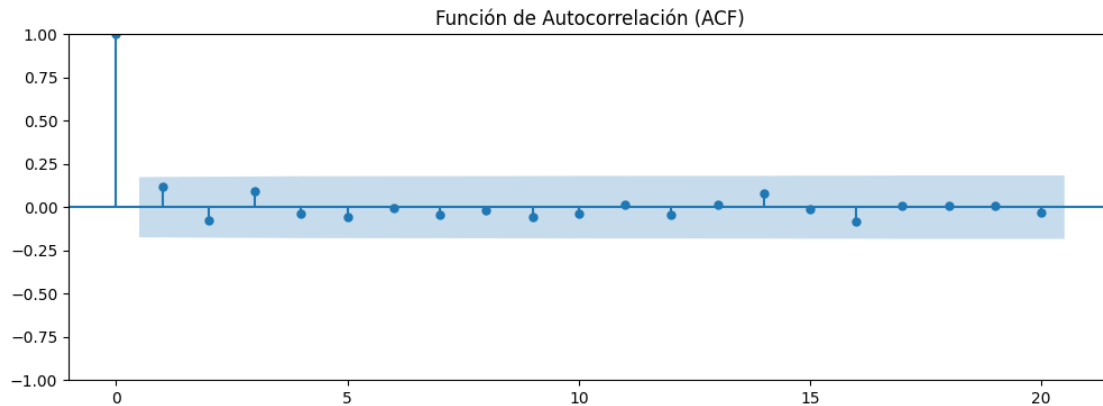
# --- Gráfico de Autocorrelación Parcial (PACF) - CORREGIDO ---
print("\nFunción de Autocorrelación Parcial (PACF):")
fig_pacf = plt.figure(figsize=(12, 4))
ax_pacf = fig_pacf.add_subplot(111)

# La corrección clave: Forzamos el método a 'ols' (Ordinary Least Squares)
# para asegurar un cálculo robusto y diferente al de la ACF.
plot_pacf(serie_crecimiento_mx, ax=ax_pacf, lags=20, method='ols')


plt.title('Función de Autocorrelación Parcial (PACF)')
plt.show()

```

Función de Autocorrelación (ACF):



Función de Autocorrelación Parcial (PACF):



Cómo interpretar los gráficos:

Para p (orden AR): Mira el gráfico PACF. Cuenta cuántos rezagos (barras azules) se salen del área sombreada azul antes de cortarse abruptamente y caer dentro del área. Si, por ejemplo, solo el primer rezago es significativo, esto sugiere un modelo $AR(1)$, es decir, $p=1$.

Para q (orden MA): Mira el gráfico ACF. De manera similar, cuenta cuántos rezagos son significativos antes de cortarse. Si el primer rezago es significativo, esto sugiere un modelo $MA(1)$, es decir, $q=1$.



El hecho de que el crecimiento tenga una memoria corta no es un problema; es la característica que explica por qué el nivel del PIB tiene una tendencia y una memoria larga. El comportamiento de los gráficos aplicados al crecimiento se conoce en econometría como un proceso de “raíz unitaria” o “caminata aleatoria”, y es la propiedad fundamental de la mayoría de las series macroeconómicas.

Para el PIB real Este gráfico está aplicado a la versión elástica del PIB real, por lo que aquí sí se puede ver correlación histórica.

```
[ ]: serie_crecimiento_real_mx = df_politica['log_pib_mx_usd'].dropna()
# Graficar ACF y PACF para identificar p y q
print("\n--- Gráficos ACF y PACF ---")
# ACF
fig_acf = plt.figure(figsize=(12, 4))
ax_acf = fig_acf.add_subplot(111)
plot_acf(serie_crecimiento_real_mx, ax=ax_acf, lags=20)
plt.title('Función de Autocorrelación (ACF) para Crecimiento en Pesos')
plt.show()

# PACF
fig_pacf = plt.figure(figsize=(12, 4))
ax_pacf = fig_pacf.add_subplot(111)
plot_pacf(serie_crecimiento_real_mx, ax=ax_pacf, lags=20, method='ols')
plt.title('Función de Autocorrelación Parcial (PACF) para Crecimiento en Pesos')
plt.show()
```

--- Gráficos ACF y PACF ---



Periodograma y Transformada discreta de fourier

```
[ ]: # --- APLICACIÓN DE FILTROS PASA-BAJA Y PASA-ALTA ---

# 1. Seleccionar la serie de nivel para el análisis
serie_original = df_politica['log_pib_mx_usd'].dropna()
N = len(serie_original) # Número de puntos de datos

# 2. Calcular la Transformada de Fourier (DFT)
# Esto nos lleva del dominio del tiempo al de la frecuencia
transformada_fft = fft(serie_original.values)
# fftfreq nos da las frecuencias correspondientes a los resultados de fft
# La frecuencia de muestreo es 4 (trimestral), el periodo es 1/4 = 0.25
frecuencias = fftfreq(N, d=1/4)

# 3. Aplicar el Filtro Pasa-Baja (Extraer la Tendencia)
# -----
# Copiamos la transformada para no modificar la original
fft_filtrada_baja = transformada_fft.copy()

# Definimos una frecuencia de corte.
# Queremos eliminar ciclos que duren menos de, por ejemplo, 3 años.
# Periodo de corte = 3 años => Frecuencia de corte = 1/3 = 0.33 ciclos/año
frecuencia_corte = 0.33

# Ponemos a cero las frecuencias que son MÁS ALTAS que la frecuencia de corte
# abs(frecuencias) > frecuencia_corte crea una máscara booleana
fft_filtrada_baja[np.abs(frecuencias) > frecuencia_corte] = 0

# Invertir la transformada para volver al dominio del tiempo
serie_filtrada_baja = ifft(fft_filtrada_baja)

# 4. Aplicar el Filtro Pasa-Alta (Extraer el Ruido/Ciclo Corto)
# -----
# Copiamos la transformada de nuevo
fft_filtrada_alta = transformada_fft.copy()

# Ponemos a cero las frecuencias que son MÁS BAJAS que la frecuencia de corte
fft_filtrada_alta[np.abs(frecuencias) < frecuencia_corte] = 0

# Invertir la transformada para volver al dominio del tiempo
serie_filtrada_alta = ifft(fft_filtrada_alta)
```

```

# 5. Visualizar los resultados
# -----
print("Generando gráfico de descomposición con filtros de Fourier...")
plt.figure(figsize=(15, 8))

# Graficar la serie original
plt.plot(serie_original.index, serie_original, label='Serie Original',
         ↪(log_pib_mx_usd)', alpha=0.7)

# Graficar el componente de baja frecuencia (la tendencia)
plt.plot(serie_original.index, serie_filtrada_baja.real, color='red',
         ↪linewidth=2.5, label='Filtro Pasa-Baja (Tendencia/Ciclo Largo)')



# Graficar el componente de alta frecuencia (el ciclo corto)
# Le sumamos la media de la serie original para que no fluctúe en cero y sea
↪comparable visualmente

plt.title('Descomposición de Series de Tiempo con Filtros de Fourier')
plt.xlabel('Año')
plt.ylabel('Escala Logarítmica')
plt.legend()
plt.grid(True)
plt.show()

# Graficamos el componente de alta frecuencia por separado para ver su
↪naturaleza estacionaria
plt.figure(figsize=(15, 5))
plt.plot(serie_original.index, serie_filtrada_alta.real, color='green')
plt.axhline(y=0, color='grey', linestyle='--')
plt.title('Componente de Alta Frecuencia Aislado (Ciclo de Corto Plazo)')
plt.ylabel('Desviación de la Tendencia')
plt.grid(True)
plt.show()

```

Generando gráfico de descomposición con filtros de Fourier...



```
[ ]: # --- Graficar la Evolución del PIB de México en Dólares (Escala Lineal) ---

# Crear la figura y los ejes para el gráfico
plt.figure(figsize=(14, 7))

# Graficar únicamente la serie de México en Millones de USD
plt.plot(df_politica.index, df_politica['pib_mx_usd'], label='PIB Real México_
↪(Millones USD)')

# Añadir títulos y etiquetas
plt.title('Evolución del PIB Real de México en Dólares (Escala Lineal)')
plt.xlabel('Periodo')
```


```

plt.ylabel('Millones de USD')
plt.legend()
plt.grid(True)

# Formatear el eje Y para que los números grandes sean más legibles
from matplotlib.ticker import FuncFormatter
def millions_formatter(x, pos):
    return f'{int(x):,}'
plt.gca().yaxis.set_major_formatter(FuncFormatter(millions_formatter))

# Mostrar el gráfico
plt.show()

```



```

[ ]: # --- ANÁLISIS DE ESTACIONALIDAD CON PERIODOGRAMA ---

# 1. Seleccionar la serie de nivel para analizar
# Usamos la serie en logaritmos y en dólares.
serie_para_ciclos = df_politica['log_pib_mx_usd'].dropna()

# 2. Definir la frecuencia de muestreo (¡Paso Crucial!)
# Como tus datos son trimestrales, tienes 4 datos por año.
frecuencia_muestreo = 4 # Datos por año

# 3. Calcular el Periodograma
# La función devuelve las frecuencias y la potencia espectral para cada una.
frecuencias, potencias = periodogram(serie_para_ciclos, fs=frecuencia_muestreo)

```



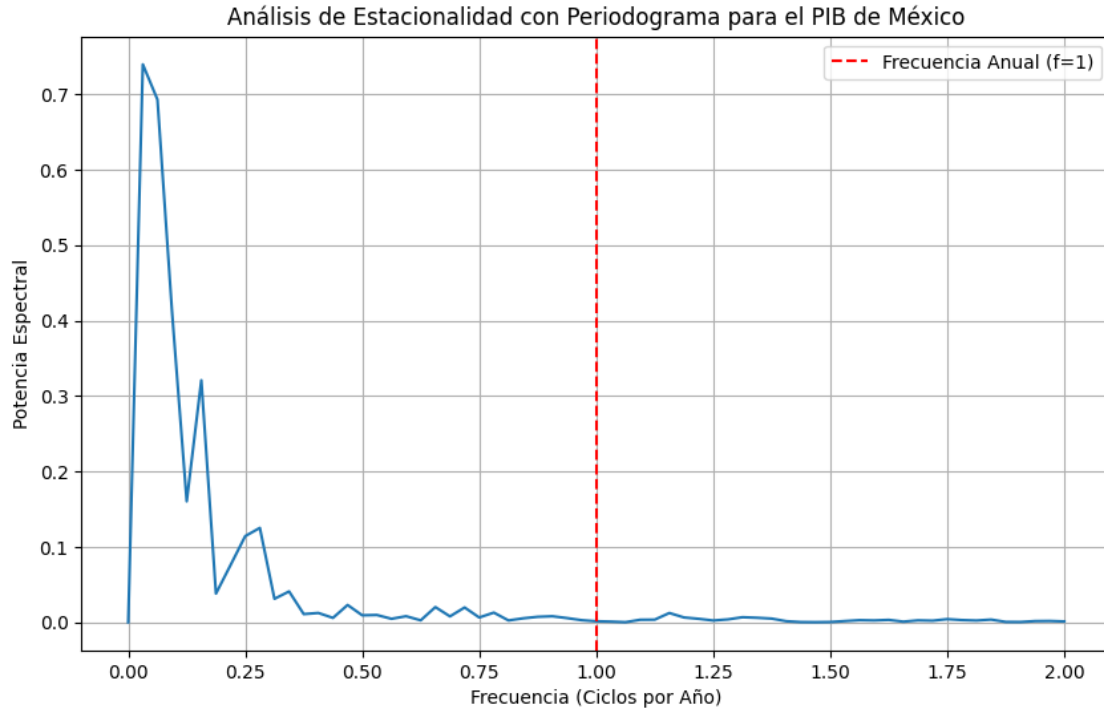
```

# 4. Graficar el Periodograma
print("Generando el Periodograma para detectar ciclos...")
plt.figure(figsize=(10, 6))
plt.plot(frecuencias, potencias)
plt.title('Análisis de Estacionalidad con Periodograma para el PIB de México_
↳(largo plazo)')
plt.xlabel('Frecuencia (Ciclos por Año)')
plt.ylabel('Potencia Espectral')
plt.grid(True)
# Marcamos la frecuencia de 1 ciclo/año, que es la más común
plt.axvline(x=1, color='red', linestyle='--', linewidth=1.5, label='Frecuencia_
↳Anual (f=1)')
plt.legend()
plt.show()

# Encontrar la frecuencia con la mayor potencia
frecuencia_pico = frecuencias[np.argmax(potencias)]
periodo_dominante = 1 / frecuencia_pico
print(f"\nLa frecuencia dominante es: {frecuencia_pico:.2f} ciclos por año.")
print(f"Esto corresponde a un periodo de: {periodo_dominante:.2f} años (o_
↳{periodo_dominante*4:.2f} trimestres).")

```

Generando el Periodograma para detectar ciclos...



La frecuencia dominante es: 0.03 ciclos por año.
Esto corresponde a un periodo de: 32.00 años (o 128.00 trimestres).

```
[ ]: ### Análisis de Estacionalidad con Periodograma

print("\n--- Análisis de Estacionalidad con Periodograma ---")

# Seleccionamos la serie estacionaria que ya creamos y limpiamos de NaNs
# Es la misma que usamos para la prueba ADF
serie_estacionaria = df_politica['crecimiento_pib_mx_usd'].dropna()

# --- Definir la Frecuencia de Muestreo (Paso Crucial) ---
# Nuestros datos son trimestrales, lo que significa que tenemos 4 puntos de
    ↪ datos por año.
# Por lo tanto, nuestra frecuencia de muestreo (fs) es 4.
fs = 4

# --- Calcular el Periodograma ---
# Esta función aplica la Transformada de Fourier y nos devuelve las frecuencias
    ↪ y su potencia
frecuencias, potencias = periodogram(serie_estacionaria, fs=fs)

# --- Graficar el Periodograma ---
plt.figure(figsize=(12, 6))
plt.plot(frecuencias, potencias)


# Añadir elementos para una mejor interpretación
plt.title('Periodograma de la Tasa de Crecimiento del PIB de México (Corto_
    ↪ plazo)')
plt.xlabel('Frecuencia (Ciclos por Año)')
plt.ylabel('Potencia Espectral')
plt.grid(True)

# Marcar con una línea roja la frecuencia de 1 ciclo/año, que es la
    ↪ estacionalidad anual
plt.axvline(x=1, color='red', linestyle='--', linewidth=1.5, label='Frecuencia_
    ↪ Anual (f=1)')
plt.legend()
plt.show()

# --- Interpretar el resultado cuantitativamente ---
# Encontrar la frecuencia con la mayor potencia (el pico más alto)
frecuencia_pico = frecuencias[np.argmax(potencias)]
periodo_pico = 1 / frecuencia_pico if frecuencia_pico > 0 else float('inf')
```

```
print(f"\nLa frecuencia dominante en la serie es: {frecuencia_pico:.4f} ciclos_
↳por año.")
print(f"Esto corresponde a un ciclo que se repite cada {periodo_pico:.2f} años_
↳(o {periodo_pico * 4:.2f} trimestres).")
```

--- Análisis de Estacionalidad con Periodograma ---



La frecuencia dominante en la serie es: 1.3858 ciclos por año.
 Esto corresponde a un ciclo que se repite cada 0.72 años (o 2.89 trimestres).

2.5.2 Estimación del Modelo

ARIMA crecimiento

```
[ ]: # Definimos los modelos candidatos que vamos a probar
modelos_a_probar = {
    "ARIMA(1,0,0)": (1, 0, 0),
    "ARIMA(0,0,1)": (0, 0, 1),
    "ARIMA(1,0,1)": (1, 0, 1)
}

# Lista para guardar los resultados
resultados = []

print("--- Ajustando y comparando modelos candidatos ---")

# Bucle para ajustar cada modelo y guardar sus criterios de información
```

```

for nombre_modelo, orden in modelos_a_probar.items():
    try:
        # Ajustar el modelo
        modelo = ARIMA(serie_crecimiento_mx, order=orden).fit()
        # Guardar resultados
        resultados.append({
            "Modelo": nombre_modelo,
            "AIC": modelo.aic,
            "BIC": modelo.bic,
            "Log-Likelihood": modelo.llf
        })
    except Exception as e:
        print(f"No se pudo ajustar el modelo {nombre_modelo}: {e}")

# Crear un DataFrame con los resultados y ordenarlo por AIC
df_resultados = pd.DataFrame(resultados).sort_values(by='AIC')

print("\n--- Tabla Comparativa de Modelos ---")
print(df_resultados)

# Encontrar el mejor modelo según AIC
mejor_modelo_aic = df_resultados.loc[df_resultados['AIC'].idxmin()]
print(f"\nEl mejor modelo según el criterio AIC es:
↳ {mejor_modelo_aic['Modelo']}")

```

--- Ajustando y comparando modelos candidatos ---

--- Tabla Comparativa de Modelos ---

	Modelo	AIC	BIC	Log-Likelihood
2	ARIMA(1,0,1)	-289.179556	-277.802808	148.589778
1	ARIMA(0,0,1)	-289.086923	-280.554362	147.543462
0	ARIMA(1,0,0)	-288.636256	-280.103695	147.318128

El mejor modelo según el criterio AIC es: ARIMA(1,0,1)

ARIMA Elasticidad PIB

```

[ ]: # Estimación y Comparación de Modelos Candidatos
modelos_a_probar = {
    "ARIMA(1,0,0)": (1, 0, 0),
    "ARIMA(0,0,1)": (0, 0, 1),
    "ARIMA(1,0,1)": (1, 0, 1)
}

resultados = []
print("\n--- Etapa 2: Ajustando y comparando modelos candidatos ---")

for nombre_modelo, orden in modelos_a_probar.items():

```

```

try:
    modelo = ARIMA(serie_crecimiento_real_mx, order=orden).fit()
    resultados.append({
        "Modelo": nombre_modelo,
        "AIC": modelo.aic,
        "BIC": modelo.bic
    })
except Exception as e:
    print(f"No se pudo ajustar el modelo {nombre_modelo}: {e}")

df_resultados_real = pd.DataFrame(resultados).sort_values(by='AIC')

print("\n--- Tabla Comparativa de Modelos para Crecimiento en Pesos ---")
print(df_resultados_real)

if not df_resultados_real.empty:
    mejor_modelo_aic_real = df_resultados_real.loc[df_resultados_real['AIC'].
↳idxmin()]
    print(f"\nEl mejor modelo según el criterio AIC es:␣
↳{mejor_modelo_aic_real['Modelo']}")
else:
    print("\nNo se pudieron ajustar los modelos.")

```

--- Etapa 2: Ajustando y comparando modelos candidatos ---

--- Tabla Comparativa de Modelos para Crecimiento en Pesos ---

	Modelo	AIC	BIC
2	ARIMA(1,0,1)	-284.859544	-273.451423
0	ARIMA(1,0,0)	-283.730983	-275.174892
1	ARIMA(0,0,1)	-73.774651	-65.218561

El mejor modelo según el criterio AIC es: ARIMA(1,0,1)